



MINISTÉRIO DA EDUCAÇÃO
UNIVERSIDADE FEDERAL DO PAMPA - UNIPAMPA
CADASTRO DE PROJETO INSTITUCIONAL



Dados do Projeto

Número de Registro:	2022.PE.AL.359	Código:	359
Coordenador:	Diego Luis Kreutz	Controle:	60004
Área:	Pesquisa	Unidade Origem:	CAMPUS ALEGRETE
Modalidade:	Projeto de Pesquisa	Telefone:	Não consta
Título:	Modelos Preditivos para Detecção de Malwares Android		
Execução:	De 10/02/2022 a 10/02/2025		
Autoriza Publicação Resumo:	Não	Área de Conhecimento:	Ciências Exatas e da Terra
Formação Continuada:	Não informado		
Grupo de Pesquisa:	LEA: Laboratório de Estudos Avançados em Computação	Possui interação com o setor produtivo:	Sim
Cooperação interinstitucional dentro do país:	Sim	Cooperação interinstitucional fora do país:	Não
Situação do Projeto:	Finalizado		
Palavras-chave:	Modelos preditivos / Detecção de Malwares / Android		

Resumo do Projeto

O sistema Android é atualmente um alvo frequente de aplicações maliciosas (*malwares*), que aumentam continuamente em número e sofisticação, exigindo o desenvolvimento contínuo de novos modelos de aprendizado de máquina para a sua detecção. Dentre os principais desafios do processo de desenvolvimento de novos modelos de aprendizado de máquina para detecção de *malwares* Android atuais podemos destacar (a) a carência de *datasets* atualizados, (b) os desafios e complexidades da modelagem e (c) a escalabilidade das soluções. Considerando estes desafios, os objetivos deste projeto são: (a) construir um *dataset* atualizado contendo características de milhões de amostras de aplicativos Android benignos e malignos recentes (e.g., 2018 a 2021); (b) investigar técnicas de seleção de características para diferentes categorias de características dos aplicativos Android; e (c) criar um arcabouço de software para incorporar recursos de limpeza dos dados, engenharia de características, seleção de características e novos métodos para seleção de hiper-parâmetros de acordo com as peculiaridades e particularidades do domínio de detecção de *malwares* Android.

Introdução e Justificativa

O sistema Android é atualmente um alvo frequente de aplicações maliciosas (*malwares*). Estudos mostram que existem modelos de aprendizado de máquina conseguem detectar *malwares* antigos com uma acurácia acima de 90% [12]. Contudo, os *malwares* aumentam continuamente em número e sofisticação, exigindo o desenvolvimento contínuo de novos modelos de detecção de *malwares* Android [10]. Dentre os principais desafios do processo de desenvolvimento de novos modelos para a identificação e a classificação de *malwares* Android atuais e sofisticados podemos destacar (a) a carência de *datasets* atualizados, (b) os desafios e complexidades da modelagem e (c) a escalabilidade das soluções. Para modelos de detecção de *malwares* Android, a atualidade dos *datasets* é

fundamen- tal e pode impactar diretamente o desempenho da solução [2, 18, 17]. Como os *malwares* Android possuem uma natureza dinâmica e uma crescente sofisticação [15], modelos de aprendizado de máquina conseguem reconhecer um aplicativo malicioso atual se os dados de treino incluírem informações sobre o comportamento de aplicativos maliciosos atuais. De fato, em um estudo recente, demonstramos que pode haver um viés significativo em modelos treinados e validados com *datasets* Android antigos [17]. Consequentemente, é imprescindível trabalharmos com *datasets* que contenham amostras de aplicativos benignos e maliciosos atuais para a construção de modelos modernos e eficazes na detecção de *malwares* Android sofisticados.

Trabalhos como [11, 14] demonstram que, na prática, a maioria absoluta dos *datasets* considerados atuais (*i.e.*, data de criação recente - 2018 a 2021) são construídos a partir de *datasets* mais antigos, o que representa um desafio para o treinamento dos modelos. Por exemplo, o *dataset* Drebin-215 (disponibilizado em 2018) é constituído por um subconjunto de dados do *dataset* Drebin, datado de 2012. O mesmo ocorre com diversos outros conjuntos de dados, como o PARUDroid, datado de 2020, que utiliza o Genome (2012) como fonte das amostras do *dataset*. Além disso, há *datasets*, como o CICInvesAndMal2019, que afirmam incluir dados atuais, de 2019, porém, contêm apenas características de versões mais antigas (*e.g.*, 2016 e inferior) da API do Android.

Além do problema da falta de *datasets* expressivos (*e.g.*, com grande quantidade de aplicativos) e, principalmente, atualizados, o desenvolvimento de soluções baseadas em aprendizado de máquina envolve diversos processos como tratamento e manipulação de dados, engenharia de características e seleção de algoritmos. O fato de tais processos muitas vezes ocorrerem de forma *ad hoc*, aliado à necessidade de conhecimento do domínio do problema a ser solucionado, torna o desenvolvimento de modelos de aprendizado de máquina custoso em tempo, dependente de conhecimento técnico especializado e difícil de ter sua viabilidade avaliada.

Ferramentas de automação de processos de aprendizado de máquina, como TPOT [9] e auto-sklearn [4], permitem obter artefatos testáveis com um custo de tempo menor em comparação com abordagens manuais. Em particular, essas ferramentas reduzem substancialmente a curva de aprendizagem uma vez que eliminam a necessidade de conhecimentos específicos da área de aprendizado de máquina. Entretanto, o usuário ainda necessita realizar ajustes finos manualmente (*e.g.*, definição do espaço de busca por melhores parâmetros, configurações de CPU e memória), o que elimina parcialmente o problema da dependência de conhecimento especializado. Além disso, essas ferramentas consomem tipicamente horas (ou até mesmo dias) para explorar as opções de otimização, seleção e treinamento de modelos, aumentando o custo computacional da validação inicial de um projeto de aprendizado de máquina.

Em uma análise experimental inicial [13], demonstramos que é tecnicamente viável construirmos ferramentas mais eficientes e eficazes que as existentes, como a TPOT e auto-sklearn. Utilizando seis *datasets* criados e disponibilizados¹ para fins de comparação entre modelos de aprendizado de máquina [8], demonstramos que o arcabouço de software proposto apresenta resultados promissores. Através do arcabouço, conseguimos reduzir significativamente o tempo de execução para construção e validação dos modelos. Resumidamente, a solução proposta identifica o algoritmo que melhor se ajusta ao problema e realiza sua otimização através de ajustes finos automatizados (*i.e.*, seleciona automaticamente hiper-parâmetros otimizados).

Além dos desafios representados pelos *datasets* desatualizados e pela criação dos modelos, podemos destacar também um terceiro grande desafio no contexto de detecção de *malwares* Android: a quantidade de dados de treinamento dos modelos. O número de características dos aplicativos Android é significativo (*i.e.*, ultrapassa facilmente um mil características), o que impacta de sobremaneira o treinamento dos modelos. Por exemplo, considerando apenas a categoria de permissões, utilizar todas as 247 permissões das APIs do Android, disponíveis para treinamento dos modelos de aprendizado de máquina, pode representar um desafio de escalabilidade [20, 6] e impactar negativamente no tempo de execução dos modelos. Portanto, além de construir os modelos, precisamos adotar também diferentes técnicas que sejam capazes de reduzir o número de características (*i.e.*, técnicas de *feature selection* específicas ao domínio) e a dimensionalidade dos *datasets*.

Considerando os desafios apresentados, isto é, construção de *datasets* que contenham dados representativos e atualizados de aplicativos Android, conhecimento e tempo necessário à construção de modelos e a quantidade e dimensionalidade dos dados, os objetivos deste projeto são: (a) construir um *dataset* atualizado contendo características de milhões de amostras de aplicativos Android benignos e malignos recentes (*e.g.*, 2018 a 2021); (b) investigar técnica(s) de seleção de características e redução da dimensionalidade para diferentes categorias de características dos aplicativos Android; e (c) desenvolver um arcabouço de software para incorporar recursos de automação da limpeza dos dados, engenharia de características, ajuste de quantidade de dados do *dataset* e novos métodos para seleção de hiper-parâmetros de acordo com as peculiaridades e particularidades desse domínio.

Objetivos

O objetivo geral de pesquisa deste projeto é construir um *dataset* atualizado e conceber um arcabouço de software para detecção de *malwares* Android atuais. Para atingir esse objetivo, os seguintes objetivos de pesquisa específicos e metas serão perseguidos durante a execução do projeto.

O1 Construir um *dataset* atualizado contendo características de milhões de amostras de aplicativos Android benignos e malignos recentes (*e.g.*, 2018 a 2021).

Meta: criar um *dataset* contendo características de pelo menos 2 milhões de aplicativos Android benignos e maliciosos.

O2 Investigar técnicas de seleção de características e redução de dimensionalidade para diferentes categorias de características dos aplicativos Android, como permissões, intenções, chamadas de API e componentes do aplicativo.

Meta: selecionar ou conceber pelo menos uma técnica de seleção de características para utilização no arcabouço de software.

O3 Investigar métodos e implementações para seleção automática de hiper-parâmetros otimizados para os modelos de detecção de *malwares* Android.

Meta: identificar, aplicar e avaliar pelo menos um método de seleção automática de hiper-parâmetros.

O4 Conceber e Evoluir um arcabouço de software para incorporar recursos de automação da limpeza dos dados, engenharia de características, ajuste de seleção de características e redução dimensionalidade dos dados do *dataset* e novos métodos para seleção de hiper-parâmetros.

Meta: 1 arcabouço de software reunindo os métodos e artefatos de software (*e.g.*, técnicas de seleção de características, seleção de hiper-parâmetros) para detecção de *malwares* Android, o *dataset* construído e publicações.

A metodologia é composta pelos processos relacionados a seguir. Esses processos serão instanciados em atividades específicas listadas no cronograma (ver Seção 5). Como será visto, a estratégia é atacar o problema geral de construção de modelos otimizados para a detecção de *malwares* Android sofisticados, através da sua divisão em subproblemas.

□ Investigação do estado da arte. Compreende o levantamento sistemático e contínuo de artigos publicados em conferências e periódicos qualificados nas áreas de segurança e inteligência artificial. Isso permite a elaboração e manutenção de um estudo consolidado acerca dos avanços científicos recentes na área.

□ Avaliação de técnicas de seleção de características. Compreende a etapa de seleção, aplicação e avaliação de técnicas de seleção de características, como a SigPID [16], SigAPI [5] e FSDroid [7]. Estas técnicas baseiam-se no princípio da identificação e da seleção das características mais relevantes para a detecção de *malwares* Android através de modelos de aprendizado de máquina, tanto supervisionados (e.g., SVM) quanto não supervisionados (e.g., CNN). Com esta avaliação, pretendemos identificar as técnicas de seleção de características que levam a melhores resultados na construção de modelos modernos de aprendizado de máquina para detecção de *malwares* Android sofisticados. Nossos estudos preliminares [3], reproduzindo a técnica do SigPID para diferentes *datasets*, indicam que esse tipo de técnica pode contribuir para reduzir significativamente a quantidade de características sem comprometer a qualidade da detecção.

□ Avaliação de métodos para seleção automática de hiper-parâmetros. Compreende a etapa de seleção e avaliação de métodos e técnicas para a seleção automática de hiper-parâmetros otimizados para os modelos de aprendizado de máquina. A otimização é crucial para o desempenho dos modelos, porém, o espaço de busca dos hiper-parâmetros pode ser significativo e impactar o tempo de concepção e a qualidade do resultado final dos modelos. Encontrar os métodos e as técnicas mais adequadas, que automatizem o processo e reduzam o tempo computacional, é fundamental para a rápida e eficaz construção automatizada de modelos. Estudos recentes [19, 1] demonstram que há diversas técnicas (e.g., GS, RS, SMAC, PSO, BOHB) que levam a diferentes níveis de complexidade em termos de tempo computacional e efeitos sobre os resultados finais dos modelos. Com o desenvolvimento desta etapa, esperamos identificar técnicas de seleção de hiper-parâmetros otimizados que gerem bons resultados em termos de tempo de computação e qualidade dos resultados finais dos modelos para detecção de *malwares* Android.

□ Avaliação e comparação do arcabouço de software proposto com soluções existentes. Compreende as etapas de planejamento e execução de experimentos. Nesta etapa, pretendemos comparar os resultados dos modelos gerados pela QuickAutoML com modelos gerados por soluções existentes, de aplicação genérica (i.e., diferentes domínios de problemas) como a TPOT [9] e auto-sklearn [4]. Isto permitirá avaliar a efetividade e a eficácia dos recursos incorporados ao arcabouço na construção de modelos de aprendizado de máquina para um domínio de problema específico, isto é, a detecção de *malwares* Android.

□ Publicação de artigos científicos. Compreende as etapas de planejamento, escrita, revisão, submissão e, quando aplicável, apresentação de trabalhos científicos em conferências e periódicos. Isso permitirá o compartilhamento de avanços com a comunidade e a obtenção de *feedback* sobre o andamento e a continuidade da pesquisa.

Relação Ensino, Pesquisa, Extensão

Ensino: fará parte de todas as atividades do projeto, com especial atenção para formação e qualificação dos discentes.

Pesquisa: Com exceção das tarefas de gestão, todas as demais atividades do projeto envolverão, de uma forma ou de outra, métodos ou técnicas de pesquisa. Essas atividades serão importantes para a formação dos discentes, egressos dos cursos de computação (Ciência da Computação, Engenharia de Software, Engenharia da Computação, Mestrado Profissional do Programa de Pós-Graduação em Engenharia de Software, Mestrado Acadêmico do Programa de Pós Graduação em Computação Aplicada) da UNIPAMPA, conforme respectivos PPCs.

Extensão: O projeto irá promover a interação, integração e intercâmbio de saberes entre a universidade e a comunidade local e/ou regional, conforme previsto nas ações do programa de extensão UniHacker.Club, registrado no SIPPEE sob o número 01.023.19, e no PDI da UNIPAMPA. A principal forma de intercâmbio de saberes será no contexto da troca de experiências e aplicação prática dos resultados de pesquisa do projeto.

Relação entre ensino, pesquisa e extensão: Os membros da equipe executora do projeto, em especial os discentes, passarão por um processo integrado e progressivo de aprendizado envolvendo ensino, pesquisa e extensão.

Aderência às áreas de Tecnologias Prioritárias do MCTI

Art. 3o A área de Tecnologias Estratégicas contempla os seguintes setores:

III - Cibernética;

O projeto irá promover o desenvolvimento do setor de cibernética, com foco em segurança cibernética, através da capacitação de recursos humanos e desenvolvimento de novas soluções (e.g., protocolos e soluções de software específicas para garantir propriedades de segurança como autenticidade, confidencialidade e privacidade de dados)

Art. 4o A área de Tecnologias Habilitadoras contempla os seguintes setores:

I - Inteligência Artificial;

II - Internet das Coisas;

O projeto irá promover a formação de recursos humanos e o desenvolvimento de soluções de Inteligência Artificial para a análise automatizada de imagens médicas.

Além disso, o projeto irá explorar a utilização de dispositivos da Internet das Coisas para executar os modelos preditivos de detecção de Malwares Android.

Geração de Resíduos

Não se aplica.

Referências

- [1] Takuya Akiba, Shotaro Sano, Toshihiko Yanase, Takeru Ohta e Masanori Koyama. □Optuna: A Next-Generation Hyperparameter Optimization Framework□. Em: *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. KDD □19. Anchorage, AK, USA: Association for Computing Machinery, 2019, pp. 2623□2631. isbn: 9781450362016. doi: 10.1145/3292500.3330701. url: <https://doi.org/10.1145/3292500.3330701>.
- [2] Kevin Allix, Tegawendé F. Bissyandé, Jacques Klein e Yves Le Traon. □Are Your Training Datasets Yet Relevant?□ Em: *Engineering Secure Software and Systems*. Ed. por Frank Piessens, Juan Caballero e Nataliia Bielova. Cham: Springer International Publishing, 2015, pp. 51□67. isbn: 978-3-319-15618-7.

- [3] Joner Assolin, Vanderson Rocha, Guilherme Silveira, Gustavo Rodrigues, Eduardo Feitosa, Karina Casola e Diego Kreutz. "Detecção de Malwares Android: reprodução da seleção de características do SigPID". Em: *VI Workshop Regional de Segurança da Informação e de Sistemas Computacionais (WRSeg)*. Charqueadas-RS, Brasil, out. de 2021. url: https://arxiv.kreutz.xyz/wrseg2021_reprodutibilidade_SigPID.pdf.
- [4] Matthias Feurer, Aaron Klein, Katharina Eggensperger, Jost Springenberg, Manuel Blum e Frank Hutter. "Efficient and Robust Automated Machine Learning". Em: *Advances in Neural Information Processing Systems* 28. Ed. por C. Cortes, N. D. Lawrence, D. D. Lee, M. Sugiyama e R. Garnett. Curran Associates, Inc., 2015, pp. 2962-2970. url: <https://papers.nips.cc/paper/5872-efficient-and-robust-automated-machine-learning.pdf>.
- [5] Asadullah Hill Galib e B M Mainul Hossain. "Significant API Calls in Android Malware Detection". Em: *32nd International Conference on Software Engineering & Knowledge Engineering (SEKE)*. KSI Research Inc. 2020, pp. -. url: https://galib19.github.io/files/SigAPI_SEKE_2020.pdf.
- [6] J. Li, L. Sun, Q. Yan, Z. Li, W. Srisa-an e H. Ye. "Significant Permission Identification for Machine-Learning-Based Android Malware Detection". Em: *IEEE Transactions on Industrial Informatics* 14.7 (2018), pp. 3216-3225. doi: 10.1109/TII.2017.2789219.
- [7] A. Mahindru e A. Sangal. "FSDroid: A feature selection technique to detect malware from Android using Machine Learning Techniques". Em: *Multimed Tools Appl* 80 (2021), pp. 13271-13323. doi: <https://doi.org/10.1007/s11042-020-10367-w>.
- [8] Randal S Olson, William La Cava, Patryk Orzechowski, Ryan J Urbanowicz e Jason H Moore. "PMLB: a large benchmark suite for machine learning evaluation and comparison". Em: *BioData mining* 10.1 (2017), pp. 1-13.
- [9] Randal S Olson e Jason H Moore. "TPOT: A tree-based pipeline optimization tool for automating machine learning". Em: *Workshop on automatic machine learning*. PMLR. 2016, pp. 66-74.
- [10] Sanjay K Sahay, Ashu Sharma e Hemant Rathore. "Evolution of malware and its detection techniques". Em: *Information and Communication Technology for Sustainable Development*. Springer, 2020, pp. 139-150.
- [11] Tejpal Sharma e Dhavleesh Rattan. "Malicious application detection in android - A systematic literature review". Em: *Computer Science Review* 40 (2021), p. 100373. issn: 1574-0137. doi: <https://doi.org/10.1016/j.cosrev.2021.100373>. url: <https://www.sciencedirect.com/science/article/pii/S1574013721000137>.
- [12] Tejpal Sharma e Dhavleesh Rattan. "Malicious application detection in android - A systematic literature review". Em: *Computer Science Review* 40 (2021), p. 100373.
- [13] Guilherme Siqueira, Gustavo Rodrigues, Eduardo Feitosa e Diego Kreutz. "QuickAutoML: Uma ferramenta para treinamento automatizado de modelos de aprendizado de máquina". Em: *VI Workshop Regional de Segurança da Informação e de Sistemas Computacionais (WRSeg)*. Charqueadas-RS, Brasil, out. de 2021. url: https://arxiv.kreutz.xyz/wrseg2021_tool_QuickAutoML.pdf.
- [14] Taina Soares, Guilherme Siqueira, Lucas Barcellos, Renato Sayyed, Luciano

- Var- gas, Gustavo Rodrigues, Joner Assolin, Jonas Pontes, Eduardo Feitosa e Diego Kreutz. □Detecção de Malwares Android: datasets e reprodutibilidade□. Em: *VI Workshop Regional de Segurança da Informação e de Sistemas Computacionais (WRSeg)*. Charqueadas-RS, Brasil, out. de 2021. url: https://arxiv.kreutz.xyz/wrseg2021_reprodutibilidade_datasets.pdf.
- [15] SophosLabs. *Sophos 2021 Threat Report*. <https://www.sophos.com/en-us/medialibrary/pdfs/technical-papers/sophos-2021-threat-report.pdf>. 2021.
- [16] Lichao Sun, Zhiqiang Li, Qiben Yan, Witawas Srisa-an e Yu Pan. □SigPID: significant permission identification for android malware detection□. Em: *2016 11th international conference on malicious and unwanted software (MALWARE)*. IEEE. 2016, pp. 1□8.
- [17] Lucas Vilanova, Renato Sayyed, Taina Soares, Guilherme Siqueira, Gustavo Rodri- gues, Eduardo Feitosa e Diego Kreutz. □Análise do impacto de viés nos conjuntos de dados para detecção de Malwares Android□. Em: *VI Workshop Regional de Se- gurança da Informação e de Sistemas Computacionais (WRSeg)*. Charqueadas-RS, Brasil, out. de 2021. url: https://arxiv.kreutz.xyz/wrseg2021_analise_vies_ML.pdf.
- [18] Fengguo Wei, Yuping Li, Sankardas Roy, Xinming Ou e Wu Zhou. □Deep Ground Truth Analysis of Current Android Malware□. Em: *Detection of Intrusions and Malware, and Vulnerability Assessment*. Ed. por Michalis Polychronakis e Michael Meier. Cham: Springer International Publishing, 2017, pp. 252□276. isbn: 978-3- 319-60876-1.
- [19] Li Yang e Abdallah Shami. □On hyperparameter optimization of machine learning algorithms: Theory and practice□. Em: *Neurocomputing* 415 (2020), pp. 295□316. issn: 0925-2312. doi: <https://doi.org/10.1016/j.neucom.2020.07.061>. url:<https://www.sciencedirect.com/science/article/pii/S0925231220311693>.
- [20] Oktay Yildiz e Ibrahim Alper Doğru. □Permission-based android malware detection system using feature selection with genetic algorithm□. Em: *International Journal of Software Engineering and Knowledge Engineering* 29.02 (2019), pp. 245□262.

Possui Bolsistas

Não, mas vou pleitear em alguma chamada

Resultados Esperados

A execução do projeto resultará em publicações e inovações, bem como promoverá impacto positivo na formação de recursos humanos e na colaboração entre grupos de pesquisa de diferentes instituições. Esperamos produzir artigos científicos compatíveis com os eventos da área, como o Simpósio Brasileiro de Segurança da Informação e de Sistemas Com- putacionais (SBSeg) e o Workshop Regional de Segurança da Informação e de Sistemas Computacionais (WRSeg).

O *dataset* criado será disponibilizado publicamente para a comunidade científica. O projeto também promoverá inovação tecnológica, que pode ser medida através de registro de software no Instituto Nacional da Propriedade Industrial (INPI).

O projeto promoverá a formação de recursos humanos com conhecimentos avançados nas áreas de segurança e inteligência artificial. Isso acontecerá através da participação de alunos em níveis de mestrado e graduação que possam realizar atividades de pes- quisa, desenvolvimento e inovação relacionadas ao projeto. É

importante observar que o proponente atua como professor do Programa de Pós-Graduação em Engenharia de Software, coordenador adjunto do Laboratório de Estudos Avançados em Computação (LEA) e coordenador do Programa Clube Universidade Hacker (UniHacker.Club), que engloba parcerias com dezenas de instituições de ensino e pesquisa e empresas do Brasil.

Em nível de graduação, o projeto deve atrair alunos dos cursos de bacharelado¹ em Ciência da Computação, Engenharia de Software e Engenharia de Computação.

Outras Informações Relevantes

Não se aplica.

Unidades e Cursos

Unidade	Curso
Campus Alegrete	Mestrado em Engenharia de Software (ALMES)
Campus Alegrete	Ciência da Computação (ALCC)
Campus Alegrete	Engenharia de Software (ALES)
Campus Bagé	Engenharia de Computação (BAEC)

Equipe Executora

Nome	E-mail	Tipo	Função	CH Semanal	Período Participação
Claudio Schepke	claudioschepke@unipampa.edu.br	Docente	Colaborador	1	De 10/02/2022 a 10/02/2024
Diego Luis Kreutz	diegokreutz@unipampa.edu.br	Docente	Coordenador	4	De 10/02/2022 a 10/02/2024
Eduardo Luzeiro Feitosa	efeitosa@icomp.ufam.edu.br	Colaborador Externo	Pesquisador	2	De 10/02/2022 a 10/02/2024
Guilherme Samuel Siqueira da Silva	guilhermesamuel79@gmail.com	Discente	Discente - Voluntário	20	De 10/02/2022 a 10/02/2024
Gustavo Rodrigues	gustavo.rodrigues@combatea fraude.com	Colaborador Externo	Colaborador	2	De 10/02/2022 a 10/02/2024
Joner de Mello Assolin	joneremello@hotmail.com	Discente	Discente - Voluntário	20	De 10/02/2022 a 10/02/2024
Karina Casola Fernandes	karinacasola@hotmail.com	Discente	Discente - Voluntário	8	De 10/02/2022 a 10/02/2024
Lucas Vilanova Barcellos	lalabarcellos0@gmail.com	Discente	Discente - Voluntário	20	De 10/02/2022 a 10/02/2024
Luciano Pereira de Vargas	lucianovargas@unipampa.edu.br	Técnico	Colaborador	2	De 10/02/2022 a 10/02/2024
Renato Sayyed de Souza	sayyedrenato@outlook.com	Discente	Discente - Voluntário	8	De 10/02/2022 a 10/02/2024
Rodrigo Brandao Mansilha	rodrigomansilha@unipampa.edu.br	Docente	Colaborador	2	De 10/02/2022 a 10/02/2024
Taina Oliveira Soares	tainaoliveira.98@gmail.com	Discente	Discente - Voluntário	20	De 10/02/2022 a 10/02/2024
Vanderson da Silva Rocha	vanderson@ufam.edu.br	Colaborador Externo	Colaborador	4	De 10/02/2022 a 10/02/2024

Cronograma

Data Início	Data Fim	Atividade	Carga Horária	Local	Membros
10/02/2022	10/02/2024	Levantamento sistemático e contínuo de artigos publicados em conferências e periódicos qualificados nas áreas de segurança e inteligência artificial;		Laboratórios de Pesquisa	Claudio Schepke, Diego Luis Kreutz, Eduardo Luzeiro Feitosa , Guilherme Samuel Siqueira da Silva, Gustavo Rodrigues, Joner de Mello Assolin, Karina Casola Fernandes, Lucas Vilanova Barcellos, Luciano Pereira de Vargas, Renato Sayyed de Souza, Rodrigo Brandao Mansilha, Taina Oliveira Soares, Vanderson da Silva Rocha
10/02/2022	10/07/2022	Construção do dataset compreensivo e atualizado, contendo um número de amostras significativo de aplicativos benignos e malignos atuais;		Laboratórios de Pesquisa	Diego Luis Kreutz, Eduardo Luzeiro Feitosa , Joner de Mello Assolin, Lucas Vilanova Barcellos, Taina Oliveira Soares, Vanderson da Silva Rocha
10/02/2022	10/09/2022	Avaliação de técnica(s) de seleção de características do dataset, isto é, redução do número de características para treinamento e validação contínua dos modelos;		Laboratórios de Pesquisa	Diego Luis Kreutz, Eduardo Luzeiro Feitosa , Guilherme Samuel Siqueira da Silva, Joner de Mello Assolin, Lucas Vilanova Barcellos, Renato Sayyed de Souza, Taina Oliveira Soares, Vanderson da Silva Rocha
10/02/2022	10/02/2024	Outras tarefas administrativas, técnicas ou técnico-científicas necessárias para o desenvolvimento do projeto.		laboratórios de Pesquisa	Claudio Schepke, Diego Luis Kreutz, Eduardo Luzeiro Feitosa , Guilherme Samuel Siqueira da Silva, Gustavo Rodrigues, Joner de Mello Assolin, Karina Casola Fernandes, Lucas Vilanova Barcellos, Luciano Pereira de Vargas, Renato Sayyed de Souza, Rodrigo Brandao Mansilha, Taina Oliveira Soares, Vanderson da Silva Rocha
10/03/2022	10/02/2023	Publicação de artigos em conferências e periódicos sobre a investigação em geral;		Laboratórios de Pesquisa	Claudio Schepke, Diego Luis Kreutz, Eduardo Luzeiro Feitosa , Guilherme Samuel Siqueira da Silva, Gustavo Rodrigues, Joner de Mello Assolin, Karina Casola Fernandes, Lucas Vilanova Barcellos, Luciano Pereira de Vargas, Renato Sayyed de Souza, Rodrigo Brandao Mansilha, Taina Oliveira Soares, Vanderson da Silva Rocha
10/06/2022	10/12/2022	Avaliação de método(s) para seleção automática de hiper-parâmetros para detecção de malwares Android;		Laboratórios de Pesquisa	Diego Luis Kreutz, Eduardo Luzeiro Feitosa , Guilherme Samuel Siqueira da Silva, Gustavo Rodrigues, Vanderson da Silva Rocha
10/07/2022	10/08/2023	Avaliação e comparação dos modelos otimizados gerados pela arcabouço de software proposto com modelos gerados por soluções existentes, de aplicação geral, como a TPOT e a auto-sklearn;		Laboratórios de Pesquisa	Claudio Schepke, Diego Luis Kreutz, Eduardo Luzeiro Feitosa , Guilherme Samuel Siqueira da Silva, Gustavo Rodrigues, Lucas Vilanova Barcellos, Renato Sayyed de Souza, Rodrigo Brandao Mansilha, Vanderson da Silva Rocha

Planejamento de Despesas

Despesas de Custeio	Opção	Valor Estimado (R\$)	Fonte de Financiamento	Especificações
Auxílio a Estudantes (Bolsas)	Não Necessita	0,00		
Diárias	Não Necessita	0,00		
Passagens	Não Necessita	0,00		
Material de Consumo	Não Necessita	0,00		
Serviços de Terceiros (Pessoa Física)	Não Necessita	0,00		
Serviços de Terceiros (Pessoa Jurídica)	Não Necessita	0,00		
Outros	Não Necessita	0,00		
Total		0,00		

Despesas de Capital	Opção	Valor Estimado (R\$)	Fonte de Financiamento	Especificações
Equipamentos e Material Permanente	Não Necessita	0,00		

Total Geral de Despesas (R\$): **0,00**

Alternativas caso a fonte de financiamento não se confirme: Não se aplica.

